

可微分记忆闭包演算：基于参数化透镜的统一框架（修正版）

摘要

本文将“记忆闭包系统”（MCS）提升为可微分、可学习的计算框架。核心贡献为：将配置图上的前向计算与参数梯度学习通过**参数化可微透镜**统一在同一个范畴结构中。我们以光滑映射笛卡尔范畴为基底，自然导出基底无关的复制结构；透镜复合定义前向求值并携带残差，其反向部分由范畴内置的反向微分组合子导出，无需外部执行记录。参数对象具备可复制结构，保证参数共享的合法性。前向合流性、反向唯一性及梯度计算正确性由透镜范畴的结合律和语义函子的重写不变性严格保证。在候选配置集合上引入输出空间的混合语义（非图松弛），将离散搜索转化为连续优化，并统一搜索与学习的动力学。进而提出基于参数共享的子图抽象与压缩定理，明确梯度独立性或弱相关性条件，给出严格的学习效率提升证明。所有构造均保持在配备反向微分结构的光滑映射对称幺半范畴及参数化透镜范畴内；所有参数均为有限维实向量，其前向值与梯度均可直接计算或通过数值代理（如随机梯度估计）近似获取，不作无意义的参数拼接。

1 引言

此前的工作将记忆闭包系统建立于对称幺半范畴、线性逻辑与组合配置图之上，形成了配置的组合代数与搜索的可靠完备性。这些构造本质上是**静态的**：给定闭包原型及其映射赋值，可计算某一配置的值。

实际智能系统需要回答两个进一步的问题：

1. **学习**：如何从经验调整闭包原型的内部参数，使某些配置的值更优？
2. **连续驱动搜索**：如何将离散的配置选择过程松弛为可微优化，从而利用梯度引导搜索？

本文的核心观察是：这两个问题的答案都蕴含在配置图的复合求值结构中。若将每个闭包实例包装为可微透镜（前向输出值及残差，反向传播余切向量），则整个配置图自动成为这些透镜的复合；前向求值即复合态射的前向部分，反向求导即该复合态射的反向部分。这种处理将反向传播完全代数化，消除了外部执行记录的额外性。连续驱动搜索通过在候选配置的输出空间构建凸组合，将结构选择转化为可微能量最小化，其梯度流引导选择概率的分配。由此，MCS 被提升为可微分记忆闭包演算。

2 范畴基础：光滑映射、反向微分与透镜

2.1 光滑映射范畴与内生复制结构

设底层范畴 $\mathcal{C}$ 定义如下：

- 对象：有限维实向量空间（例如 $\mathbb{R}^n$ ）。
- 态射： C^∞ 光滑映射。
- 么半积：取为向量空间的笛卡尔积（直积） $\times$ ，单位对象 $\mathbf{1}$ 为零维向量空间 $\{0\}$ 。
- 对称辫子：标准交换同构 $X \times Y \cong Y \times X$ 。

$\mathcal{C}$ 具有自然的可复制结构，且完全独立于基底的选取。对每个对象 X ，定义：

$$\Delta_X : X \rightarrow X \times X, \quad x \mapsto (x, x), \quad \epsilon_X : X \rightarrow \mathbf{1}, \quad x \mapsto 0.$$

这对态射使每个对象成为交换余半群，满足余结合律、余交换律与余单位律。 Δ_X 提供前向计算中的参数与数据复制语义，而其对偶在反向传播中诱导出余切向量的加法运算（多路梯度汇聚）。尽管复合是非线性的，但其态射集 $\mathcal{C}(X, Y)$ 具备由目标向量空间 Y 的线性结构所自然诱导的逐点加法与零态射结构。

2.2 反向微分结构

为使反向传播成为态射的内建操作，我们在 $\mathcal{C}$ 上配备反向微分组合子 R 。对每个态射 $f : X \rightarrow Y$ ，指定一个态射

$$R[f] : X \times Y^* \rightarrow X^*,$$

满足以下公理（反向微分范畴的标准定义）：

1. 对偶线性性： $R[f](x, \alpha)$ 对 $\alpha \in Y^*$ 是线性的。
2. 恒等律： $R[\text{id}_X](x, \alpha) = \alpha$ （利用 $X^{**} \cong X$ ）。
3. 链式法则： 对于 $f : X \rightarrow Y$ 和 $g : Y \rightarrow Z$,

$$R[g \circ f](x, \gamma) = R[f](x, R[g](f(x), \gamma)).$$

4. 么半积与对称性的兼容公理（确保与么半结构和谐）。

在光滑映射范畴中， $R[f]$ 的标准模型是雅可比矩阵的转置作用：

$$R[f](x, \alpha) = (\partial_x f(x))^\top (\alpha).$$

该操作满足全部公理，从而 $\mathcal{C}$ 构成反向微分范畴。

2.3 透镜范畴

基于反向微分结构，定义透镜范畴 $\mathbf{Lens}(\mathcal{C})$ 。

对象：与 $\mathcal{C}$ 相同。

态射：从 X 到 Y 的透镜是一对光滑映射

$$f_{\text{fwd}} : X \rightarrow Y \times R, \quad f_{\text{bwd}} : R \times Y^* \rightarrow X^*,$$

满足：存在基映射 $f_0 : X \rightarrow Y$ 和残差映射 $r : X \rightarrow R$ ，使得

$$f_{\text{fwd}}(x) = (f_0(x), r(x)), \quad f_{\text{bwd}}(r(x), \alpha) = R[f_0](x, \alpha).$$

残差 $r(x)$ 可以缓存全部输入（ $r(x) = x$ ）或仅存储反向计算所需的中间量。

复合：对于透镜 $f : X \multimap Y$ （残差 R_f ）和 $g : Y \multimap Z$ （残差 R_g ），复合 $g \circ f : X \multimap Z$ 定义为

$$(g \circ f)_{\text{fwd}}(x) = \text{let } (y, r_f) = f_{\text{fwd}}(x), (z, r_g) = g_{\text{fwd}}(y) \text{ in } (z, (r_f, r_g)),$$

$$(g \circ f)_{\text{bwd}}((r_f, r_g), \gamma) = f_{\text{bwd}}(r_f, g_{\text{bwd}}(r_g, \gamma)).$$

么半积： $(f \otimes g)_{\text{fwd}}$ 逐对执行，残差取笛卡尔积，反向类似。恒等透镜 id_X 的前向为 $x \mapsto (x, x)$ ，反向为 $(x, \alpha) \mapsto \alpha$ 。

扇出与丢弃透镜：由复制结构提升而得

$$\Delta_X^{\text{Lens}} : X \multimap X \times X, \quad f_{\text{fwd}}(x) = ((x, x), x), \quad f_{\text{bwd}}(x, (\alpha, \beta)) = \alpha + \beta,$$

$$\epsilon_X^{\text{Lens}} : X \multimap \mathbf{1}, \quad f_{\text{fwd}}(x) = (0, x), \quad f_{\text{bwd}}(x, ()) = 0.$$

它们满足余半群公理，反向的加法/零映射直接由对角映射的转置导出。

参数化透镜：参数对象 P ($\mathcal{C}$ 的对象，具备可复制结构) 用于参数化透镜。一个带参数 P 的透镜 $X \multimap Y$ 本质上是一个透镜 $P \times X \multimap Y$ 。组合时参数积累，复制操作允许多个下游共享同一参数，此时反向梯度将在所有使用处自动求和（等价于独立参数梯度之和）。

2.4 参数化闭包原型的透镜语义

定义 2.1 (参数化闭包原型). 一个参数化闭包原型 c 是四元组 $(\text{in}(c), \text{out}(c), \Theta_c, T_c)$, 其中:

- $\text{in}(c), \text{out}(c)$ 为类型列表，指定输入/输出端口序列；
- Θ_c 为参数空间，同构于 $\mathbb{R}^{p_c}$ ，元素 θ_c 称为可测量/可计算参数，其值及梯度均可通过计算或数值代理（如随机梯度估计）获得；
- $T_c : \Theta_c \times \times \text{in}(c) \rightarrow \times \text{out}(c)$ 是 $\mathcal{C}$ 中的光滑映射（ $\times$ 表示对应端口空间的笛卡尔积）。

利用反向微分结构，将 T_c 提升为参数化透镜

$$\mathcal{L}_c : \Theta_c \times \times \text{in}(c) \multimap \times \text{out}(c),$$

取基映射 T_c ，残差 $r(\theta, x) = x$ ，则

$$\begin{aligned} \mathcal{L}_c^{\text{fwd}}(\theta, x) &= (T_c(\theta, x), x), \\ \mathcal{L}_c^{\text{bwd}}(x, \alpha) &= (R[T_c]_\theta((\theta, x), \alpha), R[T_c]_x((\theta, x), \alpha)). \end{aligned}$$

其中 $R[T_c]_\theta$ 与 $R[T_c]_x$ 分别表示反向微分组合子在 Θ_c^* 和 $(\times \text{in}(c))^*$ 上的投影分量。参数梯度与输入梯度由反向映射同时给出。

3 配置图与前向求值

3.1 配置图

定义 3.1 (配置图). 一个**配置图** G 是一个带类型标注的开放式有向无环超图:

- 外部输入端口集 I , 带类型列表;
- 外部输出端口集 O , 带类型列表;
- 实例节点集 E : 每个实例 e 是某闭包原型 c 的具体出现, 带有参数 $\theta_e \in \Theta_c$;
- 有向边从实例输出端口 (或外部输入) 连至实例输入端口 (或外部输出), 类型匹配;
- 扇出由显式的对角复制透镜处理, 每个输入端口恰有一条输入边, 故无合并歧义。

无环性保证依赖为严格偏序。配置图 G 在给定外部输入 $x \in \times I$ 下, 定义一个光滑映射 $\text{val}(G) : \times I \rightarrow \times O$ 。

3.2 终端实例与含残差的收缩

定义 3.2 (终端实例). 配置图 G 中, 若实例 e 的所有输出端口均不连接任何其他实例的输入端口 (仅可能连至外部输出或悬空), 则称 e 为**终端实例**。

引理 3.3. 任何非空有限无环配置图至少拥有一个终端实例。

证明. 依赖关系 DAG 中极大元出度为 0, 即终端实例。 $\square$

定义 3.4 (终端收缩, 带残差). 设 e 为终端实例, 其原型为 c , 参数 θ_e , 当前输入向量 x_e (由上游汇聚)。执行下列图重写:

1. 计算透镜前向 $(y_e, r_e) = \mathcal{L}_c^{\text{fwd}}(\theta_e, x_e)$, 残差 r_e 记录为 x_e (或按透镜设计缓存的数据);
2. 将 y_e 分配至外部输出或忽略;

3. 在残差记录 τ 中保存存根 (e, r_e) ;

4. 从图中移除实例 e 及其所有边。

此操作将 G 变为实例数减少 1 的新图 G' , 并累积残差记录。

3.3 前向求值的合流性

引理 3.5 (局部合流). 若 G 有两个不同的终端实例 e_1, e_2 , 则收缩顺序可交换, 产生相同的最终输出与残差集合 (同构意义下)。

定理 3.6 (前向求值的合流与完备性). 任何有限无环配置图 G 均可通过有限次终端收缩完全求值, 最终外部输出 y 与残差记录 $\mathcal{R}$ 唯一切换, 不依赖于收缩顺序。

证明. 重写系统状态为 (剩余图, 累积残差存根)。每次收缩实例数严格递减, 故终止。局部合流性由引理 3.2 保证, 且终端实例收缩仅读取上游值, 不影响图中其余部分, 因此顺序可交换。由 Newman 引理, 系统全局合流, 最终结果唯一。□

4 基于透镜的反向传播

给定配置图 G 及外部输入 x , 前向求值产生输出 y 与残差记录 $\mathcal{R} = \times_e r_e$ 。设损失函数 $L : \times O \rightarrow \mathbb{R}$, 其梯度记为 $\bar{y} = \nabla_y L \in (\times O)^*$ 。

4.1 配置图对应的参数化透镜

每个闭包实例 e 给出参数化透镜 $\mathcal{L}_e$ (参数 θ_e)。利用扇出透镜和组合, 整个配置图对应于一个复合参数化透镜

$$\mathcal{G} : \Theta_{\otimes} \times \times I \multimap \times O,$$

其中 $\Theta_{\otimes} = \times_{e \in E} \Theta_{c(e)}$ 。前向部分 $\mathcal{G}^{\text{fwd}}(\theta_{\otimes}, x) = (y, \mathcal{R})$ 。反向部分 $\mathcal{G}^{\text{bwd}} : \mathcal{R} \times (\times O)^* \rightarrow (\times I)^* \times \Theta_{\otimes}^*$ 由各实例透镜的反向按复合规则合成。

4.2 反向重写算法

算法 1 (反向重写)

1. 将 $\bar{y}$ 注入外部输出端口。
2. 按前向收缩的逆序处理每个原始实例 e :
 - 从残差存根取出 r_e ;
 - 收集 e 各输出端口收到的反向梯度信号 (若该输出扇出到多个下游, 加法由扇出透镜的反向自动完成), 合成 $\bar{y}_e$;
 - 调用 $\mathcal{L}_c^{\text{bwd}}(r_e, \bar{y}_e)$, 得到 $(\bar{\theta}_e, \bar{x}_e)$;
 - 将 $\bar{\theta}_e$ 累加至全局参数梯度缓存 (参数共享时自动求和); 将 $\bar{x}_e$ 按端口分发至 e 的输入, 成为上游反向信号。
3. 最终在外部输入端口得到 $\bar{x}$ 。

定理 4.1 (反向重写的正确性). 算法 1 精确计算了损失 L 关于输入 x 和各参数 θ_e 的梯度, 结果等于 $\mathcal{G}^{\text{bwd}}(\mathcal{R}, \bar{y})$ 中对应分量。

证明. 算法步骤直接对应复合透镜 $\mathcal{G}$ 反向映射的递归展开。扇出透镜的反向为加法, 与多路梯度汇聚一致; 参数共享时梯度自动累加。因此结果等于 $\mathcal{G}^{\text{bwd}}$ 的输出。□

定理 4.2 (前向-反向不变性). 梯度计算结果不依赖于终端收缩的顺序。

证明. 定理 3.3 保证残差 $\mathcal{R}$ 唯一。 $\mathcal{G}^{\text{bwd}}$ 作为复合态射完全由组分决定, 与内部收缩顺序无关。因此梯度唯一。□

反向传播至此成为透镜组合的代数推论, 无需外部 trace。

5 候选混合语义与可微搜索

5.1 候选配置与输出空间混合

给定查询输入 x , 目标输出 O^* , 以及由闭包库生成的一族有限候选配置 $\{G_1, \dots, G_M\}$, 每个均具有相同的输出类型列表 O 。记 $y_m = \text{val}(G_m)(x) \in \times O$ 。

为将离散结构选择可微化, 我们在输出空间上构建凸组合, 而非对图结构进行松弛。引入选择权重 $\alpha \in \Delta^{M-1}$ (概率单纯形), 定义混合输出

$$\hat{O}(\alpha, \theta) = \sum_{m=1}^M \alpha_m y_m(\theta),$$

其中 θ 为所有闭包原型的参数总拼接（各原型参数空间的直积，无无关拼接）。

5.2 混合能量与退火极限

定义 5.1 (混合能量).

$$\mathcal{E}_\lambda(\alpha, \theta) = \frac{1}{2} \|\hat{O}(\alpha, \theta) - O^*\|^2 + \lambda H(\alpha),$$

$H(\alpha) = -\sum_m \alpha_m \log \alpha_m$ 为熵正则， $\lambda > 0$ 控制探索程度。

定理 5.2 (退火极限). 假设存在至少一个候选 G_* 使得 $y_* = O^*$ （完美拟合）。令 $\lambda_k \rightarrow 0^+$ ，取 $\alpha^{(k)}$ 为 $\mathcal{E}_{\lambda_k}$ 的全局极小点。则任意收敛子序列的极限 α^* 满足：

- 若唯一 G_* 匹配，则 α^* 为该候选的 *one-hot* 向量；
- 若多个候选匹配（索引集合 M_0 ），则 $\alpha_m^* = 1/|M_0|$ ($m \in M_0$)，其余为 0。

证明. 见附录 C. □

该定理表明退火可将输出混合收缩至具体配置的唯一或均匀组合，引导后续离散选择或进一步精调。

5.3 搜索与学习的统一动力学

联合优化 (α, θ) 可通过投影梯度下降实现：

$$\alpha \leftarrow \text{Proj}_\Delta(\alpha - \eta_\alpha \nabla_\alpha \mathcal{E}_\lambda), \quad \theta \leftarrow \theta - \eta_\theta \nabla_\theta \mathcal{E}_\lambda.$$

$\nabla_\alpha \mathcal{E}_\lambda$ 由拟合误差与候选输出值的向量点积及熵梯度组成。 $\nabla_\theta \mathcal{E}_\lambda$ 由第 4 节的透镜反向重写高效计算（每个候选 G_m 独立反向传播，但因输出空间共享，梯度可自然组合）。当某个 α_m 趋近 1 时，结构趋于确定，可离散固定该候选并继续学习参数。这实现了搜索与学习的无缝融合。

6 学习与压缩：可微子图抽象

6.1 可微子图抽象

在反复的搜索-学习过程中，常出现功能相同的子图模式 $H : A \rightarrow B$ ，在配置族中出现多次。**子图抽象** 操作创建一个新的参数化闭包原型 c_H ，参数 θ_H 被所有出现共享，替代原来的各异构实现。具体步骤：

1. 识别频繁且梯度方向一致的子图模式 H ；
2. 定义新闭包 c_H ，输入 A ，输出 B ；
3. 将所有 H 实例替换为 c_H 的实例，参数 θ_H 初始化为各出现的合适平均；
4. 后续学习共享 θ_H 。

6.2 压缩定理

定理 6.1 (压缩定理). 设子图 H 在配置中出现 N 次，原本每个出现可选 $b \geq 2$ 种内部实现。抽象为共享参数闭包后，搜索的局部组合路径数从 b^N 降至 1。

对于学习效率，假设每个出现对参数 θ_H 的随机梯度估计 g_k 满足：

- $\mathbb{E}[g_k] = \nabla_{\theta_H} \mathcal{L}$ (无偏)；
- $\text{Cov}(g_k) \preceq \sigma^2 I$ ；
- 跨出现梯度的协方差有界：存在 $\rho \in [0, 1)$ ，使得对所有 $i \neq j$ ，
 $\text{Cov}(g_i, g_j) \preceq \rho \sigma^2 I$ (Loewner 半正定序)。

共享参数后，参数的全局梯度为 $\tilde{g} = \sum_{k=1}^N g_k$ 。为了获得方差缩减，实际更新采用**规范化梯度** $\bar{g} = \frac{1}{N} \tilde{g}$ (可通过缩放学习率等效实现)。此时

$$\text{Cov}(\bar{g}) \preceq \frac{\sigma^2}{N} I + \left(1 - \frac{1}{N}\right) \rho \sigma^2 I.$$

若跨出现梯度独立性较强 ($\rho < 1/N$ 或很小)，方差大幅降低。在非凸光滑目标下，SGD 达到 ϵ -精度所需迭代数降低 N 倍。

证明. 见附录 D. □

推论 6.2 (偏差-方差权衡). 若不同上下文对 θ_H 的真实最优梯度方向不一致, 共享参数会引入偏差。抽象仅当跨出现梯度的平均余弦相似度较高时有利, 实践中可通过监测梯度内积均值决定是否抽象。

6.3 自举抽象过程 (推测)

推测 6.3 (自举抽象). 反复执行“搜索 $\rightarrow$ 抽象 $\rightarrow$ 压缩”循环, 可在梯度一致性条件满足时不断增长闭包库, 降低后续搜索复杂度, 逼近组合泛化的最优表达。若频繁子图在不同出现处的最优参数存在不可调和的分歧 (梯度平均余弦接近 0 或负), 抽象将引入不可弥补的偏差, 导致整体损失上升, 此时应避免抽象。该循环的收敛性及抽象空间的序结构仍需进一步形式化, 目前作为开放问题。

7 语义函子与重写不变性

7.1 配置图的范畴

定义配置图范畴 **Cfg**:

- 对象: 对 (I, O) 类型列表 (接口);
- 态射: 配置图 $G : (I, O)$, 按定义 3.1 构造;
- 恒等态射: 仅由导线构成的图;
- 复合: 图的顺序复合与并排张量积 (无交互), 形成对称幺半范畴。

终端收缩 $\rightsquigarrow$ 视为态射间的重写关系。

7.2 语义函子

定义 7.1 (语义函子). 存在对称幺半函子

$$- : \mathbf{Cfg} \longrightarrow \mathbf{Para}(\mathbf{Lens}(\mathcal{C}))$$

将每个配置图 G 映射为 4.1 节所述的参数化透镜 $\mathcal{G}$ 。具体地:

- 外部端口对应空间笛卡尔积;
- 实例 e 解释为 $\mathcal{L}_e$, 参数 θ_e 视为参数对象的一部分;

- 扇出使用 Δ^{Lens} ，导线使用恒等透镜；
- 图的复合对应透镜复合，幺半积对应平行放置，对称重排由范畴的自然同构给出。

定理 7.2 (重写保持语义). 若 $G \rightsquigarrow G'$ 是一步合法的终端收缩，则

$$G = G' \text{ 在 } \mathbf{Para}(\mathbf{Lens}(\mathcal{C})) \text{ 中.}$$

证明. 终端收缩 e 相当于将 $\mathcal{L}_e$ 与余下图进行复合。透镜复合满足严格结合律，提前执行 $\mathcal{L}_e$ 的前向并缓存残差不改变整体复合态射。扇出重联由复制透镜的自然性保证。因此语义不变。详见附录 A。 $\square$

该定理表明，命令式的“终端收缩”无非是指称语义在利用结合律逐步降解：残差存根对应复合残差对象的局部求值，算法完全臣服于语义。

推论 7.3 (语义的合流性). 由定理 7.1 及定理 3.3，任意收缩序列均导致相同的透镜态射，从而输出与梯度唯一。

8 结论与展望

本文构建了可微分记忆闭包演算，统一了以下层次：

1. **组合/范畴层**：光滑映射笛卡尔范畴与内生复制结构定义合法配置组合；
2. **几何/空间层**：计算图前向降解与残差缓存；
3. **微分/伴随层**：基于反向微分组合子的透镜范畴内化梯度传播；
4. **优化/混合层**：输出空间混合语义将离散搜索转化为连续优化。

核心结果包括：终端收缩的合流与完备性、反向传播的代数正确性、候选混合的退火极限、压缩定理的严格条件与证明，以及语义函子的重写不变性。

未来工作将向两个重要方向推进。其一，将演算拓展至**循环配置图**。当配置包含反馈环时，前向求值引入不动点迭代；在范畴论层面，需为底层的反向微分范畴配备迹结构或不动点算子 `fix`。循环透镜的前向值可由 Banach 不动点定理保证收敛，反向传播则无需展开时间步，而是求解余切

空间中的线性不动点方程，从而实现全隐式函数微分。这将使本框架从一阶 DAG 显式计算跃升为支持深层动力系统的通用可微演算。其二，深入探索自举抽象过程的收敛条件与抽象空间的序结构，并在实际神经符号系统中验证该演算的效能。

A 重写保持语义（定理 7.1）

设图 G 包含终端实例 e ，其透镜为 $\mathcal{L}_e : \Theta_e \times X_e \multimap Y_e$ ($X_e = \times \text{in}(e)$, $Y_e = \times \text{out}(e)$)。图 G 的余下部分可视为透镜 $\mathcal{H} : Y_e \times Z \multimap O$ 。整体语义为 $\mathcal{H} \circ (\mathcal{L}_e \times \text{id}_Z) \circ \sigma$ ，其中 σ 为对称重排自然同构。终端收缩操作在 G' 中移除 e ，将其输出 Y_e 作为外部输入接入 $\mathcal{H}$ ，这等于预先执行 $\mathcal{L}_e$ 前向并缓存残差，再与 $\mathcal{H}$ 复合。由于透镜复合的定义，先执行 $\mathcal{L}_e$ 再执行 $\mathcal{H}$ 与直接复合 $\mathcal{H} \circ \mathcal{L}_e$ 是同一态射。收缩未改变复合结构，结合律保证任意嵌套次序等价，因此 $G = G'$ 。

B 反向重写正确性（定理 4.1）

复合透镜 $\mathcal{G}$ 的反向部分按定义递归计算：对于 $\mathcal{G} = \mathcal{H} \circ \mathcal{L}_e$ ，反向为

$$\mathcal{G}^{\text{bwd}}((r_e, r_{\mathcal{H}}), \gamma) = \mathcal{L}_e^{\text{bwd}}(r_e, \mathcal{H}^{\text{bwd}}(r_{\mathcal{H}}, \gamma)).$$

算法 1 的逆序处理先计算下游梯度 $\mathcal{H}^{\text{bwd}}$ ，再传递给 $\mathcal{L}_e^{\text{bwd}}$ ，并使用缓存的 r_e 。扇出透镜反向将多路梯度加和，匹配 $\mathcal{H}$ 内部的加法；参数共享时梯度自然累加。通过归纳整个图结构，最终得到完整的梯度映射，等于 $\mathcal{G}^{\text{bwd}}(\mathcal{R}, \bar{y})$ 。

C 退火极限的严格证明（定理 5.1）

记 $y_m = \text{val}(G_m)(x)$ ，误差函数 $f(\alpha) = \frac{1}{2} \|\sum_m \alpha_m y_m - O^*\|^2$ 。令 $Z = \{\alpha \in \Delta^{M-1} \mid f(\alpha) = 0\}$ ，由假设非空。对任意 $\lambda > 0$ ， $\mathcal{E}_\lambda(\alpha) = f(\alpha) + \lambda H(\alpha)$ 。

设 $\lambda_k \rightarrow 0^+$ ， $\alpha^{(k)}$ 为 $\mathcal{E}_{\lambda_k}$ 在紧集 Δ^{M-1} 上的全局极小点（连续函数在紧集上达到最小值，故存在）。取任意 $\beta \in Z$ ，有

$$f(\alpha^{(k)}) + \lambda_k H(\alpha^{(k)}) \leq f(\beta) + \lambda_k H(\beta) = \lambda_k H(\beta).$$

于是 $f(\alpha^{(k)}) \leq \lambda_k(H(\beta) - H(\alpha^{(k)}))$ 。熵在单纯形上有界，故当 $k \rightarrow \infty$ ，右端趋于 0，从而 $f(\alpha^{(k)}) \rightarrow 0$ 。由单纯形的紧致性，存在收敛子列 $\alpha^{(k_j)} \rightarrow \alpha^*$ ，且 $f(\alpha^*) = 0$ ，即 $\alpha^* \in Z$ 。

再证 α^* 在 Z 中熵极大。对任意 $\beta \in Z$ ，

$$\lambda_k H(\alpha^{(k)}) \leq \lambda_k H(\beta) - f(\alpha^{(k)}) \leq \lambda_k H(\beta),$$

即 $H(\alpha^{(k)}) \leq H(\beta)$ 。取极限得 $H(\alpha^*) \leq H(\beta)$ 。因此 α^* 是 Z 上熵的极大点。

Z 是单纯形与仿射子空间（方程 $\sum \alpha_m y_m = O^*$ ）的交集，为凸多面体。若 Z 仅含一个顶点（唯一完美候选），则极大熵点即该顶点。若 Z 为更高维面，由熵 H 在单纯形上的严格凹性，其限制在凸集 Z 上的极大值必在 Z 的相对内部唯一取到，且为 Z 各顶点权重的均匀分布（满足零误差的候选被赋予相等概率）。因此 α^* 必为所述形式。

D 压缩定理学习部分详证（定理 6.1 学习效率）

设全局损失 $\mathcal{L}(\theta_H)$ ，第 k 次出现的随机梯度估计 g_k 满足 $\mathbb{E}[g_k] = \nabla \mathcal{L}$ ， $\text{Cov}(g_k) \preceq \sigma^2 I$ ，且 $i \neq j$ 时 $\text{Cov}(g_i, g_j) \preceq \rho \sigma^2 I$ 。全局真实梯度为 $\tilde{g} = \sum_{k=1}^N g_k$ 。更新采用规范化梯度 $\bar{g} = \frac{1}{N} \tilde{g}$ ，其期望仍为 $\nabla \mathcal{L}$ 。协方差计算如下：

$$\begin{aligned} \text{Cov}(\bar{g}) &= \frac{1}{N^2} \left(\sum_{k=1}^N \text{Cov}(g_k) + \sum_{i \neq j} \text{Cov}(g_i, g_j) \right) \\ &\preceq \frac{1}{N^2} (N\sigma^2 I + N(N-1)\rho\sigma^2 I) \\ &= \frac{\sigma^2}{N} I + \left(1 - \frac{1}{N}\right) \rho\sigma^2 I. \end{aligned}$$

当 $\rho = 0$ 时，方差降至原来的 $1/N$ ；当 $\rho < 1/N$ 时，仍显著降低。根据非凸 SGD 理论，达到 $\mathbb{E}[\|\nabla \mathcal{L}\|^2] \leq \epsilon$ 的迭代复杂度为 $O(\sigma_{\text{eff}}^2/\epsilon^2)$ ，有效方差 σ_{eff}^2 的最大特征值经上述界缩减，故迭代数减少 N 倍。证毕。